# PASS/LAS Biostatistiques — fiche formules

Formules, valeurs usuelles, exemples chiffrés et pièges : notions fréquentes en PASS/LAS ; les enseignements varient selon les facultés

Clairance

## Statistique descriptive

Moyenne $\overline{x} = (\sum x_i)/n$ ; médiane : valeur centrale de la série ordonnée ($n$ pair : moyenne des deux valeurs centrales) ; mode : valeur la plus fréquente.

$$s^2 = \frac{\sum (x_i - \overline{x})^2}{n-1} \qquad \sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$$

Écart-type $s = \sqrt{s^2}$, dans l'unité des données. $s^2$ : estimation à partir d'un échantillon ; $\sigma^2$ : population entière.

**EXEMPLE Série 2, 4, 4, 5, 10**

$\overline{x} = 5$ ; $s^2 = 9$ ; $s = 3$. Médiane 4 < moyenne : la valeur 10 tire la moyenne vers le haut.

## Probabilités

$P(\overline{A}) = 1 - P(A)$ ; $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \qquad P(A \cap B) = P(A \mid B)P(B)$$

Indépendants : $P(A \cap B) = P(A)P(B)$, soit $P(A \mid B) = P(A)$. Incompatibles : $P(A \cap B) = 0$. Bayes, avec les probabilités totales :

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B \mid A)P(A) + P(B \mid \overline{A})P(\overline{A})}$$

## Tests diagnostiques

| | Malades (M) | Non malades |
|---|---|---|
| Test + | VP | FP |
| Test − | FN | VN |

Se = VP /(VP + FN) ; Sp = VN /(VN + FP). VPP = VP /(VP + FP) ; VPN = VN /(VN + FN). Par Bayes, avec la prévalence $P$ :

$$\text{VPP} = \frac{\text{Se}\,P}{\text{Se}\,P + (1 - \text{Sp})(1 - P)}$$

Se et Sp décrivent le test ; VPP et VPN dépendent aussi de la prévalence.

**EXEMPLE Maladie rare**

Se 0,9, Sp 0,95, $P$ = 0,02 (valeurs d'exercice) : VPP ≈ 27 % ; VPN ≈ 99,8 %. Un test positif reste le plus souvent un faux positif.

## Lois de probabilité

Binomiale $\mathcal{B}(n, p)$ : $n$ épreuves indépendantes, deux issues, même $p$.

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$E = np \qquad V = np(1-p)$$

Poisson $\mathcal{P}(\lambda)$ : $P(X = k) = e^{-\lambda}\lambda^k / k!$ ; $E = V = \lambda$. Approche $\mathcal{B}(n, p)$ si $n$ grand et $p$ petit, avec $\lambda = np$. Normale $\mathcal{N}(\mu, \sigma^2)$ : $Z = (X - \mu)/\sigma$ suit $\mathcal{N}(0, 1)$.

**EXEMPLE Binomiale, Poisson, centrage**

$\mathcal{B}(4; 0{,}1)$ : $P(X = 1) = 4 \times 0{,}1 \times (1 - 0{,}1)^3 = 0{,}2916$. $\mathcal{P}(2)$ : $P(X = 2) = e^{-2} \times 2^2/2 \approx 0{,}271$. $\mu = 100$, $\sigma = 15$, $x = 130$ : $z = 2$.

| Normale | ±1σ | ±2σ | ±3σ |
|---|---|---|---|
| Part des valeurs | 68 % | 95 % | 99,7 % |

## Estimation

Erreur standard de la moyenne : $\sigma/\sqrt{n}$ (théorème central limite : $\overline{X}$ approximativement normale si $n$ grand). IC d'une moyenne, $n$ grand : $\overline{x} \pm z_{\alpha/2} s/\sqrt{n}$. Petit $n$ (population normale) : $t$ de Student à $n - 1$ ddl à la place de $z$. IC d'une proportion : $p \pm z_{\alpha/2}\sqrt{p(1-p)/n}$, si $np$ et $n(1-p) > 5$.

**EXEMPLE Intervalles de confiance à 95 %**

$\overline{x} = 5{,}2$, $s = 2$, $n = 100$ : IC ≈ [4,81 ; 5,59]. $p = 0{,}2$, $n = 400$ : IC ≈ [16,1 ; 23,9] (en %).

| Confiance | α bilatéral | $z_{\alpha/2}$ |
|---|---|---|
| 90 % | 0,10 | 1,645 |
| 95 % | 0,05 | 1,96 |
| 99 % | 0,01 | 2,576 |

## Tests d'hypothèse

$H_0$ (pas de différence) contre $H_1$ (uni- ou bilatérale). $\alpha = P$(rejeter $H_0 \mid H_0$ vraie), risque de 1re espèce ; $\beta = P$(ne pas rejeter $H_0 \mid H_0$ fausse), risque de 2e espèce ; puissance $1 - \beta$. $p$ : probabilité, si $H_0$ est vraie, d'un résultat au moins aussi éloigné de $H_0$ que celui observé. $p < \alpha$ : rejet de $H_0$. Deux moyennes, grands échantillons indépendants :

$$z = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

**EXEMPLE Deux moyennes**

12 ($s = 3$) contre 11 ($s = 2{,}5$), $n = 100$ par groupe : $z \approx 2{,}56 > 1{,}96$, différence significative à 5 %.

## Khi-deux

$$\chi^2 = \sum \frac{(O - E)^2}{E} \qquad E = \frac{T_l \times T_c}{N}$$

$O$ observé, $E$ attendu sous $H_0$ (indépendance) ; $T_l$, $T_c$ : totaux de la ligne et de la colonne. ddl = $(l - 1)(c - 1)$ ; chaque $E \geq 5$.

| Seuil $\chi^2$ | ddl | α |
|---|---|---|
| 3,841 | 1 | 0,05 |
| 6,635 | 1 | 0,01 |
| 5,991 | 2 | 0,05 |

## Corrélation et régression

$r = \text{cov}(x, y)/(s_x s_y)$, $-1 \leq r \leq 1$ ; $r^2$ : part de la variation de $y$ expliquée par la droite. Moindres carrés : $\hat{y} = a + bx$, $b = r s_y / s_x$, $a = \overline{y} - b\overline{x}$ ; la droite passe par $(\overline{x}, \overline{y})$.

**EXEMPLE Droite de régression**

$r = 0{,}8$, $s_x = 2$, $s_y = 5$ : $b = 2$ ; $\overline{x} = 10$, $\overline{y} = 30$ : $a = 10$ ; $r^2 = 0{,}64$.

## Épidémiologie

Incidence cumulée = nouveaux cas / population à risque au début de la période. Taux d'incidence = nouveaux cas / somme des personnes-temps. Prévalence = cas existants / population, à un instant ou sur une période ; elle dépend de l'incidence et de la durée de la maladie.

| Étude | Principe : mesure |
|---|---|
| Expérimentale | exposition attribuée par l'investigateur (essai randomisé), puis suivi |
| Cohorte | exposés et non exposés suivis, incidences comparées : RR |
| Cas-témoins | malades et témoins, expositions passées comparées : OR |
| Transversale | exposition et maladie mesurées en même temps : prévalence |

| | Malades | Non malades |
|---|---|---|
| Exposés | $a = 30$ | $b = 70$ |
| Non exposés | $c = 15$ | $d = 85$ |

Cohorte : RR = $(a/(a + b))/(c/(c + d))$. Cas-témoins : OR = $ad/(bc)$, proche du RR si la maladie est rare.

**EXEMPLE Même tableau**

RR = 2 ; OR ≈ 2,43. $E_a = 100 \times 45/200 = 22{,}5$ ; $\chi^2 \approx 6{,}45 > 3{,}841$ (ddl 1) : association significative à 5 %.

**PIÈGE**

- Variance d'échantillon : diviser par $n - 1$, pas par $n$.
- Écart-type (dispersion des données) ≠ erreur standard (précision de la moyenne).
- Incompatibles ≠ indépendants : deux événements incompatibles de probabilité non nulle sont dépendants.
- $P(A \mid B) \neq P(B \mid A)$ : Se ≠ VPP.
- Ne pas rejeter $H_0$ ne prouve pas $H_0$ (puissance).
- $p$ n'est pas la probabilité que $H_0$ soit vraie.
- Khi-deux : effectifs, jamais des pourcentages.
- Corrélation ≠ causalité ; $r$ ne mesure qu'une liaison linéaire.
- Prévalence (stock) ≠ incidence (flux).