PASS/LAS Biostatistiques — fiche formules

Formules, valeurs usuelles, exemples chiffrés et pièges : notions fréquentes en PASS/LAS ; les enseignements varient selon les facultés

Clairance

Statistique descriptive

Moyenne $\bar{x} = \left(\sum x_i\right)/n$; médiane : valeur centrale de la série ordonnée (n pair : moyenne des deux valeurs centrales) ; mode : valeur la plus fréquente.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} \qquad \sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$$

Écart-type $s = \sqrt{s^2}$, dans l'unité des données. s^2 : estimation à partir d'un échantillon ; σ^2 : population entière.

EXEMPLE Série 2, 4, 4, 5, 10

$\bar{x} = 5$; $s^2 = 9$; $s = 3$. Médiane 4 < moyenne : la valeur 10 tire la moyenne vers le haut.

Probabilités

$P(\overline{A}) = 1 - P(A)$;
$P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Si $P(B) > 0$:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \qquad P(A \cap B) = P(A \mid B)P(B)$$

Indépendants : $P(A \cap B) = P(A)P(B)$, soit $P(A \mid B) = P(A)$. Incompatibles : $P(A \cap B) = 0$. Bayes, avec les probabilités totales :

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B \mid A)P(A) + P\left(B \mid \overline{A}\right)P\left(\overline{A}\right)}$$

Tests diagnostiques

	Malades	Non malades
Test +	VP	FP
Test −	FN	VN

Se = VP/(VP + FN) ; Sp = VN/(VN + FP). VPP = VP/(VP + FP) ; VPN = VN/(VN + FN). Par Bayes, avec la prévalence P :

$$\text{VPP} = \frac{\text{Se}\,P}{\text{Se}\,P + (1 - \text{Sp})(1 - P)}$$

$$\text{VPN} = \frac{\text{Sp}(1 - P)}{\text{Sp}(1 - P) + (1 - \text{Se})P}$$

Se et Sp décrivent le test ; VPP et VPN dépendent aussi de la prévalence.

EXEMPLE Maladie rare

Se = 0,9 ; Sp = 0,95 ; P = 0,02 (valeurs d'exercice) : VPP ≈ 27 % ; VPN ≈ 99,8 %. Un test positif reste le plus souvent un faux positif.

Lois de probabilité

Binomiale $\mathcal{B}(n, p)$: n épreuves indépendantes, deux issues, même p.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$E = np \qquad V = np(1 - p)$$

Poisson $\mathcal{P}(\lambda)$: $P(X = k) = e^{-\lambda}\lambda^k / k!$; $E = V = \lambda$. Approche $\mathcal{B}(n, p)$ si n grand et p petit, avec $\lambda = np$. Normale $\mathcal{N}(\mu, \sigma^2)$: $Z = (X - \mu)/\sigma$ suit $\mathcal{N}(0, 1)$.

EXEMPLE Binomiale, Poisson, centrage

$\mathcal{B}(4 ; 0{,}1)$: $P(X = 1) = 4 \times 0{,}1 \times (1 - 0{,}1)^3 = 0{,}2916$. $\mathcal{P}(2)$: $P(X = 2) = e^{-2} \times 2^2/2 \approx 0{,}271$. $\mu = 100$, $\sigma = 15$, $x = 130$: $z = 2$.

Normale	±1σ	±2σ	±3σ
Part des valeurs	≈ 68 %	≈ 95 %	≈ 99,7 %

Estimation

Erreur standard de la moyenne : $\sigma/\sqrt{n}$, estimée par $s/\sqrt{n}$ (théorème central limite : $\bar{X}$ approximativement normale si n grand). IC d'une moyenne, n grand : $\bar{x} \pm z_{\alpha/2} s/\sqrt{n}$. Petit n (population normale) : t de Student à $n - 1$ ddl à la place de z. IC d'une proportion observée $\hat{p}$, si $n\hat{p}$ et $n(1 - \hat{p}) > 5$:

$$\hat{p} \pm z_{\alpha/2}\sqrt{\hat{p}(1 - \hat{p})/n}$$

EXEMPLE Intervalles de confiance à 95 %

$\bar{x} = 5{,}2$, $s = 2$, $n = 100$: IC ≈ [4,81 ; 5,59]. $\hat{p} = 0{,}2$, $n = 400$: IC ≈ [16,1 ; 23,9] (en %).

Confiance	α bilatéral	$z_{\alpha/2}$
90 %	0,10	1,645
95 %	0,05	1,96
99 %	0,01	2,576

Tests d'hypothèse

H_0 (pas de différence) contre H_1 (uni- ou bilatérale). $\alpha = P$(rejeter $H_0 \mid H_0$ vraie), risque de 1re espèce ; $\beta = P$(ne pas rejeter $H_0 \mid H_0$ fausse), risque de 2e espèce ; puissance $1 - \beta$. p : probabilité, si H_0 est vraie, d'un résultat au moins aussi éloigné de H_0 que celui observé. $p < \alpha$: rejet de H_0. Deux moyennes, grands échantillons indépendants :

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

EXEMPLE Deux moyennes

12 ($s = 3$) contre 11 ($s = 2{,}5$), $n = 100$ par groupe : $z \approx 2{,}56 > 1{,}96$, différence significative à 5 %.

Khi-deux

$$\chi^2 = \sum \frac{(O - E)^2}{E} \qquad E = \frac{T_l \times T_c}{N}$$

O observé, E attendu sous H_0 (indépendance) ; T_l, T_c : totaux de la ligne et de la colonne. ddl = $(l - 1)(c - 1)$; chaque $E \geq 5$.

Seuil χ^2	ddl	α
3,841	1	0,05
6,635	1	0,01
5,991	2	0,05

Corrélation et régression

$r = \text{cov}(x, y)/\left(s_x s_y\right)$, $-1 \leq r \leq 1$; r^2 : part de la variation de y expliquée par la droite. Moindres carrés : $\hat{y} = a + bx$, $b = r s_y / s_x$, $a = \bar{y} - b\bar{x}$; la droite passe par $(\bar{x}, \bar{y})$.

EXEMPLE Droite de régression

$r = 0{,}8$, $s_x = 2$, $s_y = 5$: $b = 2$; $\bar{x} = 10$, $\bar{y} = 30$: $a = 10$; $r^2 = 0{,}64$.

Épidémiologie

Incidence cumulée = nouveaux cas / population à risque au début de la période. Taux d'incidence = nouveaux cas / somme des personnes-temps. Prévalence = cas existants / population, à un instant ou sur une période ; elle dépend de l'incidence et de la durée de la maladie.

Étude	Principe : mesure
Expérimentale	exposition attribuée par l'investigateur (essai randomisé), puis suivi
Cohorte	exposés et non exposés suivis, incidences comparées : RR
Cas-témoins	malades et témoins, expositions passées comparées : OR
Transversale	exposition et maladie mesurées en même temps : prévalence

	Malades	Non malades
Exposés	$a = 30$	$b = 70$
Non exposés	$c = 15$	$d = 85$

Cohorte : RR = $(a/(a + b))/(c/(c + d))$. Cas-témoins : OR = $ad/(bc)$, proche du RR si la maladie est rare ; le RR n'y est pas calculable.

EXEMPLE Même tableau, lu comme une cohorte

RR = 2 ; OR ≈ 2,43. $E_a = 100 \times 45/200 = 22{,}5$; $E_b = 77{,}5$, $E_c = 22{,}5$, $E_d = 77{,}5$; $\chi^2 \approx 6{,}45 >$ 3,841 (ddl 1) : association significative à 5 %.

PIÈGE

- Variance d'échantillon : diviser par $n - 1$, pas par n.
- Écart-type (dispersion des données) ≠ erreur standard (précision de la moyenne).
- Incompatibles ≠ indépendants : deux événements incompatibles de probabilité non nulle sont dépendants.
- $P(A \mid B) \neq P(B \mid A)$: Se ≠ VPP.
- Ne pas rejeter H_0 ne prouve pas H_0 (puissance).
- p n'est pas la probabilité que H_0 soit vraie.
- Khi-deux : effectifs, jamais des pourcentages.
- Corrélation ≠ causalité ; r ne mesure qu'une liaison linéaire.
- Prévalence (stock) ≠ incidence (flux).